

# Modelos GARCH

Wilson Freitas

## Introdução

O objetivo é apresentar os modelos da família GARCH demonstrando a formulação básica e chegando até a estimação de parâmetros. Na prática estes modelos tem origem no modelo ARCH proposto por [1], onde GARCH é uma evolução proposta por [2]. Neste documento todos estes modelos serão chamados de GARCH por simplificação.

Um ponto sobre estes modelos é que eles são citados como modelos de volatilidade, no entanto, a volatilidade de uma série temporal não é observada. Na prática os modelos GARCH são aplicados a séries retornos financeiros (tipicamente estacionárias de primeira ordem) onde a volatilidade da série tem um componente autoregressivo e daí é que vem a referência a modelagem de volatilidade para estes modelos. Dessa forma, ao longo do texto os modelos serão aplicados a séries  $r_t$  que tipicamente são séries de retorno.

## Modelo ARCH

O modelo ARCH segue

$$r_t = \sqrt{h_t} e_t$$

e

$$h_t = \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2$$

onde  $h_t$  é a variância de  $r_t$  e  $e_t$  são os incrementos aleatórios com

- $E[e_t] = 0$
- $E[e_t^2] = 1$
- $E[e_s e_t] = 0$  para qualquer  $s \neq t$

que como veremos podem assumir diferentes distribuições. A variância em  $h_t$  depende de retornos em  $t-1, t-2, t-3, \dots$ , por isso este modelo é dito autoregressivo na variância. Esta é a definição de um modelo ARCH de ordem  $p$  que considera  $p$  termos autoregressivos de  $r_t$  na variância, de forma simplificada denomina-se ARCH(p).

Nota: não está sendo considerada a forma mais geral do modelo ARCH(p) em que se tem ainda um termo de média do processo.

## Esperanças incondicionais

Dada a definição de ARCH temos as esperanças incondicionais

$$\begin{aligned} E r_t &= E \sqrt{h_t} e_t \\ &= E \sqrt{h_t} E e_t \\ &= 0 \end{aligned}$$

$$\begin{aligned} E r_t^2 &= E h_t e_t^2 \\ &= E h_t E e_t^2 \\ &= E h_t \\ &= \omega + \sum_{i=1}^p \alpha_i E r_{t-i}^2 \end{aligned}$$

Com  $E r_t = 0$  podemos escrever

$$\text{Var } r_t = E r_t^2$$

Assim o resultado acima pode ser escrito como

$$\text{Var } r_t = \omega + \sum_{i=1}^p \alpha_i \text{Var } r_{t-i}$$

e como  $r_t$  é um processo estacionário  $\text{Var } r_t = \text{Var } r_s$  para qualquer  $s$ . Portanto,

$$\begin{aligned} \text{Var } r_t &= \omega + \sum_{i=1}^p \alpha_i \text{Var } r_t \\ &= \frac{\omega}{1 - \sum_{i=1}^p \alpha_i} \end{aligned}$$

É importante notar que para chegar a estes resultados estamos assumindo que

- $E[\sqrt{h_t} e_t] = E[\sqrt{h_t}] E[e_t]$  e
- $E[h_t e_t^2] = E[h_t] E[e_t^2]$

ou seja,  $\sqrt{h_t}$  é independente de  $e_t$  e  $h_t$  é independente de  $e_t^2$ . Talvez devesse desenvolver melhor este argumento.

## Esperanças condicionais

Se considerarmos as esperanças condicionadas à informação até o instante  $t - 1$  temos:

$$\begin{aligned} E_{t-1}[r_t] &= E[r_t | I_{t-1}] \\ &= E[\sqrt{h_t} e_t | I_{t-1}] \\ &= E[\sqrt{h_t} | I_{t-1}] E[e_t | I_{t-1}] \\ &= \sqrt{h_t} E[e_t | I_{t-1}] \\ &= 0 \end{aligned}$$

$$\begin{aligned}
E_{t-1}[r_t^2] &= E[r_t^2|I_{t-1}] \\
&= E[h_t e_t^2|I_{t-1}] \\
&= E[h_t|I_{t-1}] E[e_t^2|I_{t-1}] \\
&= h_t|I_{t-1}
\end{aligned}$$

Note que  $h_t|I_{t-1}$  não tem componente aleatória, é dado pelas realizações passadas de  $r_t$ , ou seja, é um escalar.

## Escrevendo ARCH com um AR

Nas seções anteriores demonstrou-se que  $E_{t-1}[r_t^2] = h_t|I_{t-1}$ . Usando este resultado define-se a variável  $u_t$  como:

$$\begin{aligned}
u_t &= r_t^2 - E_{t-1}[r_t^2] \\
&= r_t^2 - h_t
\end{aligned}$$

onde  $u_t$  é o erro na esperança condicional. Note que na equação acima foi colocado  $h_t|I_t \equiv h_t$  para não carregar a notação e que  $u_t$  tem esperança condicional zero  $E_{t-1} u_t = 0$ .

Reescrevendo a equação de  $u_t$  como

$$\begin{aligned}
r_t^2 &= h_t + u_t \\
&= \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2 + u_t
\end{aligned}$$

obtem-se uma equação de  $r_t^2$  como um processo AR(p).

## Modelo GARCH

O GARCH é uma extensão do ARCH proposta por [2], onde uma componente autoregressiva da variância é introduzida na equação da variância. Dessa forma, a variância  $h_t$  passa a ter termos com retornos e variância passados.

$$r_t = \mu_t + \sqrt{h_t} e_t$$

e

$$h_t = \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2 + \sum_{i=1}^q \beta_i h_{t-i}$$

## Esperança incondicional

$$E r_t = 0$$

$$\begin{aligned}
 E r_t^2 &= E h_t \\
 &= \omega + \sum_{i=1}^p \alpha_i E r_{t-i}^2 + \sum_{i=1}^q \beta_i E h_{t-i} \\
 &= \omega + \sum_{i=1}^p \alpha_i E r_{t-i}^2 + \sum_{i=1}^q \beta_i E r_{t-i}^2 \\
 &= \omega + E r_t^2 \left( \sum_{i=1}^p \alpha_i + \sum_{i=1}^q \beta_i \right) \\
 &= \frac{\omega}{1 - \sum_{i=1}^p \alpha_i - \sum_{i=1}^q \beta_i} \\
 &\equiv \text{Var } r_t
 \end{aligned}$$

Esta formulação é uma generalização porque permite que para  $\beta_i = 0$  se retorne a formulação ARCH(p).

Da mesma forma que um modelo ARMA(1,1) pode ser escrito como um modelo AR( $\infty$ ), um modelo GARCH(1,1) pode ser escrito como um modelo ARCH( $\infty$ ),

$$\begin{aligned}
 h_t &= \omega + \alpha_1 r_{t-1}^2 + \beta_1 h_{t-1} \\
 &= \omega + \alpha_1 r_{t-1}^2 + \beta_1 (\omega + \alpha_1 r_{t-2}^2 + \beta_1 h_{t-2}) \\
 &= \omega(1 + \beta_1) + \alpha_1 (r_{t-1}^2 + \beta_1 r_{t-2}^2) + \beta_1^2 h_{t-2} \\
 &= \omega(1 + \beta_1 + \beta_1^2) + \alpha_1 (r_{t-1}^2 + \beta_1 r_{t-2}^2 + \beta_1^2 r_{t-3}^2) + \beta_1^3 h_{t-3} \\
 &\vdots \\
 &= \frac{\omega}{1 - \beta_1} + \alpha_1 \sum_{i=0}^{\infty} r_{t-1-i}^2 \beta_1^i
 \end{aligned}$$

Assim, um modelo GARCH de baixa ordem deve ter propriedades similares a modelos ARCH de alta ordem, com isso evitando os problemas inerentes a estimação de parâmetros sujeitos a restrições de não-negatividade.

Alguns trabalhos sugerem a utilização de um decaimento linear para os coeficientes do modelo ARCH, de forma que os únicos parâmetros sejam a ordem  $p$  do modelo e a somatória dos coeficientes. Mesmo assim o modelo GARCH é uma solução mais parsimoniosa e natural ao modelo ARCH uma vez que a estimação de parâmetros ainda é mais simples e produz resultados melhores.

## Esperança condicional

$$\begin{aligned}
 E_{t-1} r_t &= 0 \\
 \text{Var}_{t-1} r_t &= h_t \\
 &= \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2 + \sum_{i=1}^p \beta_i h_{t-i} \\
 &= \omega + \alpha(L) r_t^2 + \beta(L) h_t
 \end{aligned}$$

## Escrevendo GARCH com um ARMA

Seja

$$\begin{aligned}
 u_t &= r_t^2 - E_{t-1} r_t^2 \\
 &= r_t^2 - h_t \\
 &= r_t^2 - \omega - \sum_{i=1}^p \alpha_i r_{t-i}^2 - \sum_{i=1}^q \beta_i h_{t-i} \\
 &= r_t^2 - \omega - \sum_{i=1}^p \alpha_i r_{t-i}^2 - \sum_{i=1}^q \beta_i (r_{t-i}^2 - u_{t-i}) \\
 &= r_t^2 - \omega - \sum_{i=1}^p \alpha_i r_{t-i}^2 - \sum_{i=1}^q \beta_i r_{t-i}^2 + \sum_{i=1}^q \beta_i u_{t-i} \\
 \\ 
 r_t^2 &= \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2 + \sum_{i=1}^q \beta_i r_{t-i}^2 + u_t - \sum_{i=1}^q \beta_i u_{t-i} \\
 &= \omega + \sum_{i=1}^{\max(p,q)} (\alpha_i + \beta_i) r_{t-i}^2 + u_t - \sum_{i=1}^q \beta_i u_{t-i}
 \end{aligned}$$

onde tem-se um ARMA(p,q) e  $p \equiv \max(p, q)$ .

## Modelo EWMA ou IGARCH(1,1)

Considere um processo GARCH(1,1) onde

$$h_t = \omega + \alpha r_{t-1}^2 + \beta h_{t-1}$$

Foi visto anteriormente que a variância incondicional de  $r_t^2$  nesse processo é dada por

$$\text{Var } r_t^2 = \frac{\omega}{1 - \alpha - \beta}$$

onde surge como restrição a equação:  $1 - \alpha - \beta \geq 0$ . Ao considerar o limite dessa restrição chega-se a  $\alpha + \beta = 1$  onde pode-se reduzir a uma única variável assumindo  $\alpha = 1 - \lambda$  e  $\beta = \lambda$ . Neste contexto a variância incondicional de  $r_t^2$  diverge e o processo passa a ser não estacionário.

A equação da variância condicional

$$h_t = \omega + (1 - \lambda) r_{t-1}^2 + \lambda h_{t-1}$$

é denominada IGARCH(1,1) ou EWMA (Exponentially Weighted Moving Average)

## Esperança incondicional

$$\mathbb{E} r_t = 0$$

$$\begin{aligned}\mathbb{E} r_t^2 &= \mathbb{E} h_t \\ &= \omega + (1 - \lambda)\mathbb{E} r_{t-1}^2 + \lambda\mathbb{E} h_{t-1} \\ &= \omega + (1 - \lambda)\mathbb{E} r_{t-1}^2 + \lambda\mathbb{E} r_{t-1}^2 \\ &= \omega + \mathbb{E} r_{t-1}^2\end{aligned}$$

$$\mathbb{E} r_t^2 - \mathbb{E} r_{t-1}^2 = \omega$$

Dado que  $r_t^2$  é não estacionário essa análise não me diz muito nesse momento.

## Esperança condicional

$$\begin{aligned}\mathbb{E}_{t-1}[r_t] &= \mathbb{E}[r_t | I_{t-1}] \\ &= \mathbb{E}[\sqrt{h_t} e_t | I_{t-1}] \\ &= \mathbb{E}[\sqrt{h_t} | I_{t-1}] \mathbb{E}[e_t | I_{t-1}] \\ &= \sqrt{h_t} \mathbb{E}[e_t | I_{t-1}] \\ &= 0\end{aligned}$$

$$\begin{aligned}\mathbb{E}_{t-1}[r_t^2] &= h_t | I_{t-1} \\ &= \omega + (1 - \lambda)r_{t-1}^2 + \lambda h_{t-1} | I_{t-1}\end{aligned}$$

## Análise com o erro da esperança condicional

$$\begin{aligned}u_t &= r_t^2 - \mathbb{E}_{t-1} r_t^2 \\ &= r_t^2 - h_t \\ &= r_t^2 - \omega - (1 - \lambda)r_{t-1}^2 - \lambda h_{t-1} \\ &= r_t^2 - \omega - (1 - \lambda)r_{t-1}^2 - \lambda(r_{t-1}^2 - u_{t-1}) \\ &= r_t^2 - r_{t-1}^2 - \omega - \lambda u_{t-1}\end{aligned}$$

$$r_t^2 - r_{t-1}^2 = \omega + u_t - \lambda u_{t-1}$$

Posto dessa forma, o processo de  $r_t^2$  não é estacionário, como já mencionado anteriormente.  $r_t^2$  é um processo integrado de ordem 1 pois a sua primeira diferença gera um processo estacionário. O processo de  $r_t^2$  tem características de um *random walk*. Assumindo  $r_0^2$  constante o processo pode ser reescrito como:

$$r_t^2 = r_0^2 + \sum_{i=1}^t (u_i - \lambda u_{i-1})$$

assim

$$\mathbb{E} r_t^2 = r_t^2$$

$$\begin{aligned}\text{Var } r_t^2 &= \sum_{i=1}^t \text{Var}(u_i - \lambda u_{i-1}) \\ &= (1 + \lambda^2)t \text{Var } u_i\end{aligned}$$

que é claramente dependente de  $t$  e portanto o processo  $r_t^2$  é não estacionário.

## Processos Integrados

$x_t$  é um processo integrado de ordem 1, notado por  $x_t \sim I(1)$ , se tem a forma

$$x_t = x_{t-1} + u_t$$

onde  $u_t$  é uma série temporal estacionária. Claramente tem-se que:

$$\Delta x_t = u_t$$

é estacionário (seguindo definição de  $u_t$ ).

Acumulando processo  $x_t$  desde a origem  $x_0$  tem-se

$$y_t = y_0 + \sum_{i=1}^t u_i$$

e o somatório de  $u_i$  representa a tendência estocástica do processo.

Se  $u_t \sim N(0, \sigma^2)$  então  $x_t$  é chamado de *random walk* (RW). Se  $x_t$  é RW e assumindo  $x_0$  constante tem-se:

$$\begin{aligned}\mathbb{E} x_t &= x_0 \\ \text{Var } x_t &= \sigma^2 t \\ \text{Cov}(x_t, x_{t-s}) &= (t-s)\sigma^2 \\ \text{Cor}(x_t, x_{t-s}) &= \sqrt{\frac{t-s}{t}}\end{aligned}$$

## Referências

- [1] R. F. Engle, *Econometrica: Journal of the Econometric Society* (1982).
- [2] T. Bollerslev, *Journal of Econometrics* **31**, 307 (1986).